TP02
Modelos de Recuperación

Matias Rolón
143354

1. Dados los siguientes documentos, arme la matriz término-documento (TD)[1]

- *Doc1 = {El software libre ha tenido un papel fundamental en el crecimiento de Internet. Además, Internet ha favorecido la comunicación entre los desarrolladores de software y ha permitido una mayor colaboración.}*
- *Doc2 = {La mayor riqueza que tiene un país es la cultura, eso lo hace más libre. El acceso a Internet tiene un papel importante en la producción de conocimiento y el intercambio de información.}*
- *Doc3 = {La producción de software es fundamental para nuestro país, como así también lo es la producción de tecnología de hardware y comunicación. Es esencial fomentar la innovación en tecnología.}*
- *Doc4 = {La cultura del software libre está en crecimiento. Es fundamental que nuestro país incorpore software libre en el estado.}*
- *Doc5 = {El intercambio de conocimiento y la colaboración abierta son pilares de la cultura libre. La tecnología debe ser accesible para todos los ciudadanos.}*
- *Doc6 = {La infraestructura de Internet es vital para el crecimiento económico y la igualdad de oportunidades. El software libre contribuye a una mayor soberanía tecnológica.}*

¿Qué documentos se recuperan en cada caso para las siguientes consultas booleanas? (Muestre mediante operaciones con conjuntos cómo se resuelven las consultas)

a) (not software) or (pais and fundamental)
b) producción and (cultura or libre)
c) fundamental or libre or país
d) (accesible or vital) and not (libre)

Respuesta

Las operaciones se pueden encontrar en el archivo ***Punto_1.ods***, en la hoja "*BOOL*".

[1] utilice la planilla disponible en https://github.com/tolosoft-academia/RI_2025/blob/main/data/Matriz_TD_base.ods

Query	Operaciones	Resultado
a	=> {d2,d5} or ({d3} and {d4}) => {d2,d5} or {d3,d4} => {d2,d5,d3,d4}	**doc2, doc5, doc3, doc4**
b	=> {d2,d3} and {d1,d2,d4,d5,d6} => {d2}	**doc2**
c	=> {d1,d3,d4} **or** {d1,d2,d4,d5,d6} **or** {d2,d3,d4} => {d1,d2,d3,d4,d5,d6}	**doc1, doc2, doc3, doc4, doc5, doc6**
d	=> ({d5} or {d6}) **and** {d3} => {d5,d6} **and** {d3} => **{}**	**{}**

Tabla 1: Resultados de queries booleanas

2. *Utilizando los documentos del ejercicio anterior, arme la matriz TD pero calculando w_{ij} como la frecuencia del i-ésimo término en el j-ésimo documento. Calcule el ranking para las siguientes consultas utilizando como ḿetrica el producto escalar y luego repita con la métrica del coseno.*

a) software pais fundamental
b) producción cultura libre
c) fundamental libre país
d) accesible vital libre

Respuesta
Las operaciones se pueden encontrar en el archivo ***Punto_2.ods***, en la hoja "*TF2".*

Query	Producto Escalar	Cosenos
a	1. doc4 2. doc1 / doc3 3. doc2 / doc6 4. doc5	1. doc4 2. doc3 3. doc1 4. doc6 5. doc2 6. doc5
b	1. doc2 / doc4 2. doc3 / doc5 3. doc1 / doc6	1. doc4 2. doc2 3. doc5 4. doc3 5. doc6 6. doc1
c	1. doc4 2. doc1 / doc2 / doc3 3. doc5 / doc6	1. doc4 2. doc2 3. doc3 4. doc1 5. doc5 6. doc6
d	1. doc4 / doc5 / doc6 2. doc1 / doc2 3. doc3	1. doc5 2. doc4 / doc6 3. doc2 4. doc1 5. doc3

Tabla 2: Resultados de queries con pesos TF

3. *Rearme la matriz del ejercicio anterior, pero calcule los pesos de acuerdo a TF/IDF. Repita todas las consultas (por ambos modelos de similitud). ¿Puede obtener alguna conclusión?*

Respuesta

Las operaciones se pueden encontrar en el archivo ***Punto_3.ods***, en la hoja "*TFIDF*"

Query	Producto Escalar	Cosenos
a	1. doc4 2. doc3 3. doc1 4. doc2 5. doc6 6. doc5	1. doc4 2. doc3 3. doc1 4. doc2 5. doc6 6. doc5
b	1. doc3	1. doc3

	2. doc2 3. doc4 4. doc5 5. doc1 / doc6	2. doc2 3. doc4 4. doc5 5. doc1 6. doc6
c	1. doc4 2. doc3 3. doc1 / doc2 4. doc5 / doc6	1. doc4 2. doc3 3. doc1 4. doc2 5. doc5 6. doc6
d	1. doc5 / doc6 2. doc4 3. doc1 / doc2 4. doc3	1. doc5 2. doc6 3. doc4 4. doc1 5. doc2 6. doc3

Tabla 3: Resultados de queries con pesos TF*IDF

Se observa que para todas las consultas, el método de **tf*idf mejora situaciones de empates** que pueden darse con la similitud con producto escalar. Ejemplo: En la query **"a"** tanto **doc1** como **doc3** quedan con la misma puntuación, por lo que no queda claro cual poner primero en el ranking (en este caso se decidió ponerlas a ambas en el mismo). Tal situación ya no sucede con tf*idf ya que la similitud deja primero a **doc3** (0.21) y luego a **doc1** (0.15). Esto mejora genera rankings menos confusos.
Aunque esta última situación de los empates pase más con producto escalar, también se da en menor medida (query **d**) con coseno, asi que podríamos decir que es una desventaja general del método de pesos sólo tomando TF.
En cuanto a la similitud de los rankings, vemos que entre el punto 1 y 2 hay varios cambios entre sí, teniendo con la medida de coseno cambios en **todas** las queries, con foco en la **b** y la **c**, que sufren cambios en las primeras 3 posiciones del ranking, lo que resulta una diferencia más relevante, en comparación con si sucediera más abajo en el ranking.
Como a nivel conceptual el coseno normaliza el valor según la longitud de los documentos, podríamos considerarlo como más "justo".

4. *Utilizando pyTerrier, indexe la colección Wiki-Small[2]. Tome 5 necesidades de información y, de forma manual, derive una consulta (query). Para cada una, pruebe la recuperación por los modelos basados en TF/IDF y BM25. ¿Cómo se comportan los rankings? Calcule el coeficiente de correlación para los primeros 10, 25 y 50 resultados. ¿Qué conclusiones obtiene?*

2 http://dg3rtljvitrle.cloudfront.net/wiki-small.tar.gz

Respuesta

Se penalizaron aquellos documentos que estén en un ranking pero no en el otro, haciendo que ocupen la posición k+1, siendo ***k*** el número máximo del ranking. Al obtener el top 50 de todas las consultas, se asumió la posición 51 para los documentos que no aparecieran en un método de recuperación.

Query	Ranking	Coeficiente de correlación
1. python programming language	Top 10	0,62
	Top 25	0,62
	Top 50	0,59
2. world war II countries	Top 10	0,94
	Top 25	0,97
	Top 50	0,98
3. plants argentina	Top 10	1
	Top 25	1
	Top 50	0,99
4. science fiction books	Top 10	0,99
	Top 25	0,99
	Top 50	1
5. population nagasaki japan	Top 10	1
	Top 25	0,99
	Top 50	0,99

Tabla 4: Coef. de Correlacion entre ranking con TF*IDF y BM25

En todas las consultas, exceptuando la primera, los ranking se comportaron de manera muy similar, teniendo un coeficiente de correlación muy alto, siempre superior a 0,9.

Con respecto a esa primera consulta, no se obtuvieron ranking similares, sin embargo el nivel de correlación se mantiene a medida que aumenta K (10, 25 y 50). Quizás es la que tenga términos más generales, y por lo tanto ambiguos, entre todas las queries hechas, lo que ayude a tener resultados muy distintos. Por “general” nos referimos a que puede tener muchas apariciones en todos los documentos y tener más de un significado, al ser “python” un lenguaje de

programación (que puede aparecer en artículos técnicos) o un animal; y “language” puede ser uno de programación o uno humano.

5. *Escriba un script que lea un directorio con documentos de texto y arme una estructura de datos en memoria para soportar la recuperación. Luego, debe permitir ingresar una consulta y devolver un ranking de los documentos relevantes utilizando el modelo vectorial. Use TF/IDF según MIR [1]:* $(1 + \log(freq_{i,j})) \times \log(N / n_i)$

Respuesta
El código que cumple con la consigna se puede encontrar en la carpeta “Punto 5“ siendo *TP02_P5.py*[3] el archivo principal.

5.1 *Indexe la colección del ejercicio 4 con su software. Ejecute las consultas y compare los resultados con los obtenidos con pyTerrier. ¿Son consistentes?*

Respuesta
Se puede encontrar en la carpeta *“Punto 5.1”* los archivos .csv con el ranking devuelto para cada consulta. Ejemplo: *“plants_argentina.csv”*
La comparación completa con el ranking del sistema del ejercicio 4 se muestra en la planilla *Punto_5_1.ods*

K	Q1	Q2	Q3	Q4	Q5
10	0,13	0,69	-0,35	0,46	0,93
25	0,74	0,37	0,64	0,40	0,75
50	0,55	0,40	0,65	0,46	0,55

Tabla 5.1: Coeficiente de correlación entre ranking de Ejercicios 4 y 5

Los rankings no fueron consistentes en su totalidad.
Como mejores casos tenemos a las queries 2 y 5 donde se tiene buena correlación en la primera parte del ranking (top 10). Aunque luego ambas van decreciendo mucho a medida que aumenta el ranking. Este buen desempeño al comienzo podría deberse a que son quizás las *queries* más específicas que se realizaron.
Por el lado de la query 4 es la que tuvo una correlación más estable a lo largo de los diferentes valores de K, aunque no por eso un valor bueno, ya que sigue considerándose una correlación baja.
En cuanto a la query 3, destaca que es la única que tuvo un coeficiente negativo entre todas las consultas realizadas (inversamente proporcionales). Por ende los sistemas ordenan esta consulta al revés entre ellos.
Por último, la query 1 indica que en el top 10 dieron resultados muy dispares, pero luego se corrige pronunciadamente para el top 25, ya que ronda casi un 75% de

[3] Al inicio del archivo tendrá ejemplos de cómo invocarlo.

correlación, para luego bajar a 55% en la posición 50. Resultados muy variables entre sí, propios de una consulta que, como ya se mencionó en otros puntos, puede resultar más ambigua que las demás a la hora de resolverla.

6. *Se requiere evaluar la performance en la recuperación de un sistema. Para una consulta q1, dicho sistema entregó la siguiente salida:*

1	*2*	*3*	*4*	*5*	*6*	*7*	*8*	*9*	*10*	*11*	*12*	*13*	*14*	*15*
R	*N*	*N*	*R*	*R*	*N*	*N*	*N*	*N*	*R*	*N*	*N*	*N*	*R*	*N*

Los documentos identificados como R son los relevantes, mientras que las N's corresponden a documentos no relevantes a q1. Suponga, además, que existen en el corpus otros 6 documentos relevantes a q1 que el sistema no recuperó. A partir de esta salida, calcule las siguientes medidas:

a) Recall y Precisión para cada posición j.
b) Precisión promedio.
c) Precisión al 50 % de Recall.
d) Precisión-R.
e) DCG@10, IDCG@10 y nDCG@10
f) MRR

Finalmente, realice las gráficas interpolada y sin interpolar. Luego, interprete brevemente los resultados y brinde una explicación.

Respuesta
Se muestran los resultados a continuación. Las operaciones se pueden encontrar en el archivo ***Punto_6.ods*.**

Ranking	Recall	Precisión
1	0,09	1,00
2	0,09	0,50
3	0,09	0,33
4	0,18	0,50
5	0,27	0,60
6	0,27	0,50
7	0,27	0,43

8	0,27	0,38
9	0,27	0,33
10	0,36	0,40
11	0,36	0,36
12	0,36	0,33
13	0,36	0,31
14	0,45	0,36
15	0,45	0,33

Tabla 6.a: Recall y Precisión para cada posición j.

Punto	**Métrica**	**Valor**
6.b	Precisión promedio	0.26
6.c	Precisión al 50% de recall	0
6.d	Precisión R	0.36
6.e	DCG@10	2.11
	DCG@10	4.54
	NDCG@10	0.46
6.f	MRR	1

Tabla 6.b: Métricas.

Se observa un sistema que no llegó a recuperar ni la mitad de los relevantes (5 de 11). La precisión promedio es baja, no supera los 0,5. Recupera relevantes pero no los suficientes ni en las posiciones ideales del ranking. Esto también se condice con la métrica de recall al 50% de 0, ya que nunca logra alcanzar dicho valor.

La ganancia acumulada (nDCG) dió 0,46, lo que no es una medida alta. Esto sugiere que hay docs relevantes recuperados tarde en el ranking. Ejemplo de esto son los dos relevantes que se recuperan a partir de la posición 10, lo que queda lejano a las primeras posiciones, sobre todo teniendo en cuenta que es un ranking corto (15 posiciones).
Quizás la métrica más engañosa sea el MRR que dió 1, lo que indica que el primer relevante fue recuperado al inicio del ranking, un buen inicio. Sin embargo, al sólo

medir el primer documento relevante encontrado se pierde la perspectiva completa del sistema.

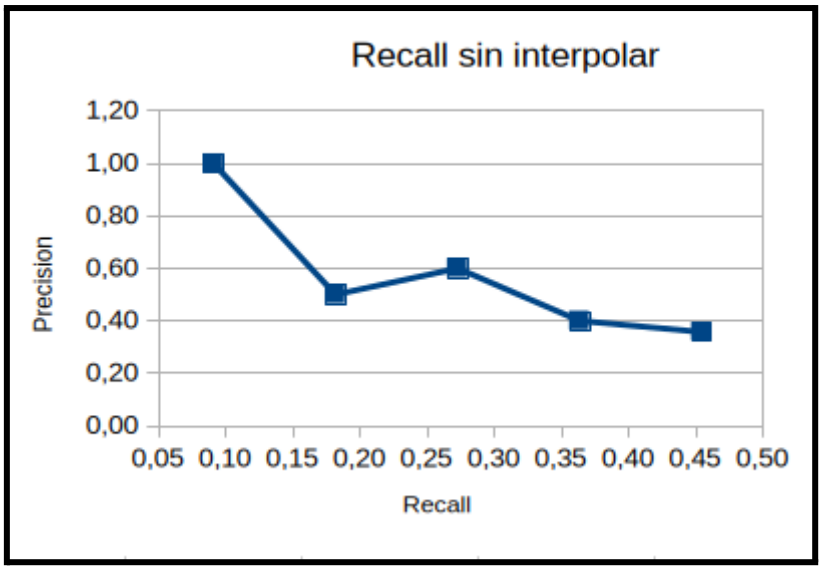

Gráfico 6.1: Precisión-Recall sin interpolar

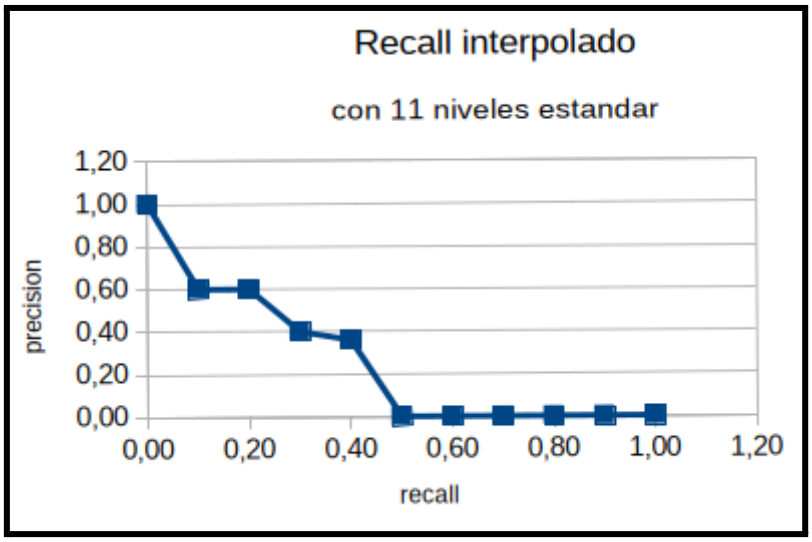

Gráfico 6.2: Precisión-Recall interpolada en 11 niveles estándar

Finalmente, si observamos los gráficos de la relación Precisión-Recall, en especial **Gráfico 6.1** vemos inestabilidad en la precisión, ya que empieza alta, baja y luego vuelve a subir para finalmente bajar una última vez. Esto nos podría indicar mucha alternancia entre relevantes y no relevantes, sin concentrarlos en un rango específico.

Por el lado de **Gráfico 6.2** podemos ver un rendimiento **aceptable** mientras el recall es bajo (es decir, durante la recuperación de los primeros relevantes). Esto se puede intuir cuando vemos la recuperación de 3 documentos relevantes en el top 5

(bien), y luego tener los 2 restantes en posiciones muy separadas del ranking (10 y 14), que hace que la precisión a partir de la posición 5 se desmorone por debajo del 50%, de manera rápida y ya no se recupere.

En conclusión, el SRI no es adecuado si se quiere hacer una búsqueda exhaustiva ya que nunca logra llegar a un recall del 50% siquiera. Tal vez sirva para una búsqueda rápida, mostrando resultados aceptables en las primeras posiciones.

7. *Utilizando la colección de prueba Vaswani y pyTerrier se debe realizar la evaluación del sistema. Para ello, es necesario construir un índice con los documentos de la colección y luego ejecutar las consultas (modelo vectorial con TF/IDF), las cuales deben armar a partir de los términos que considere de las necesidades de información (puede eliminar las palabras vacías). Los resultados deben ser comparados contra los juicios de relevancia de la colección. Realizar el análisis en dos ámbitos:*

1) *Global (promedio de todas la consultas), para las siguientes métricas: P@10, AP, NDCG@10 e incluya la gráfica de R–P en los 11 puntos estándar.*
2) *Individual (por query), para las mismas métricas, calculando la distribución de los valores en cada caso.*

Respuesta
La notebook final con la que se obtuvieron los gráficos y métricas finales se puede encontrar en el archivo ***Punto_7.ipynb***

7.1 Análisis global
Con una precisión promedio de 3.6 documentos relevantes en promedio para las primeras 10 posiciones de cada ranking, el sistema logra recuperar algunos documentos relevantes pero no muchos, al menos no de forma consistente entre todas las queries, ya que hay al menos 6 documentos no relevantes en el top10.
Si vemos la precisión promedio total (AP=0.29) podemos ver que no tiene un desempeño alto en esa métrica. Es decir, recupera documentos relevantes pero no están bien ordenados en el ranking. Confirmamos esto último con la última métrica general, el nDGG, la cual penaliza encontrar docs relevantes en posiciones bajas del ranking, y cuyo valor es de 0.44, de manera que no logra ser sobresaliente.

Métrica	Promedio
P@10	0.36
AP	0.29
nDCG@10	0.44

Tabla 7.1: Promedio de métricas entre todas las queries

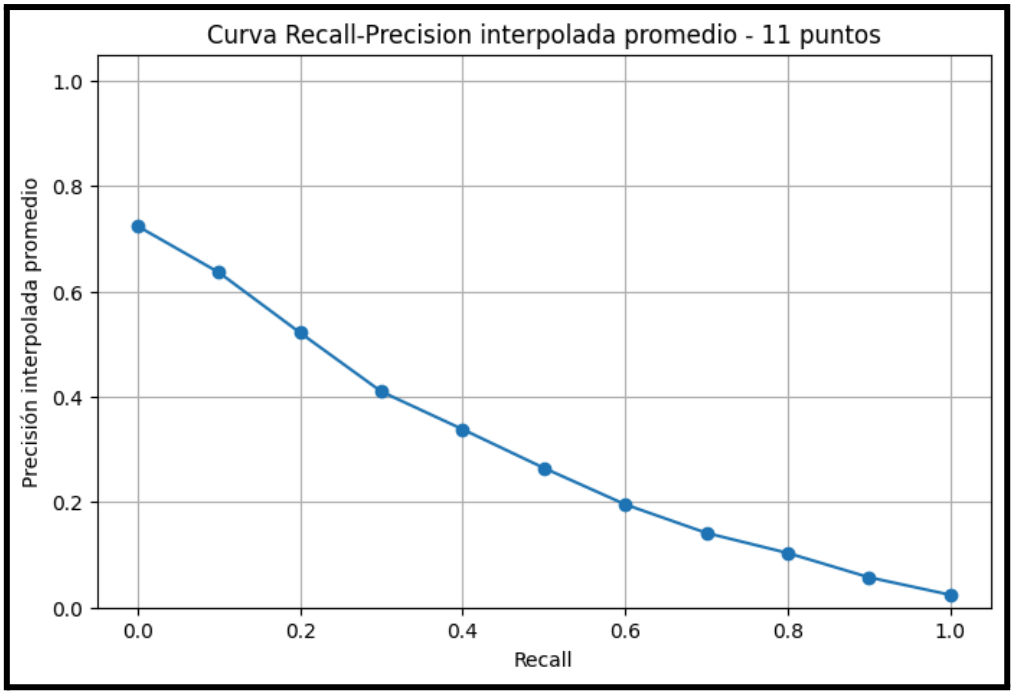

Gráfico 7.1: Precisión promedio interpolada en puntos estándar

Luego, cuando vemos el **Gráfico 7.1**, la curva muestra una caída pronunciada en los primeros niveles de recall (hasta 0.3), lo que indica que, si bien el sistema recupera documentos relevantes en las primeras posiciones, rápidamente introduce no relevantes. Se condice con las métricas anteriores de P@10.

A partir de ese punto (posterior a 0.3), la disminución de la precisión se vuelve más gradual. Por ejemplo, si tomamos el mismo largo de 3 niveles, de 0.3 a 0., vemos que la precisión bajó sólo 0.2, cuando en el primer ejemplo de 3 niveles (de 0 a 0.3) había decaído una cantidad de 0.3. Esto sugiere un comportamiento más estable del sistema en niveles intermedios de recuperación.

7.2 Análisis individual

En la distribución de P@10 del **Histograma 7.2.a** podemos ver que la misma es muy dispersa, ya que no sobresale por amplia diferencia ningún rango de valor en particular por sobre otros. Se nota una “concentración” entre 0 y 0.5 aprox, pero es un rango muy amplio. No hay ningún ranking perfecto (10/10) pero si unos pocos casos con 0.9, que es un desempeño óptimo

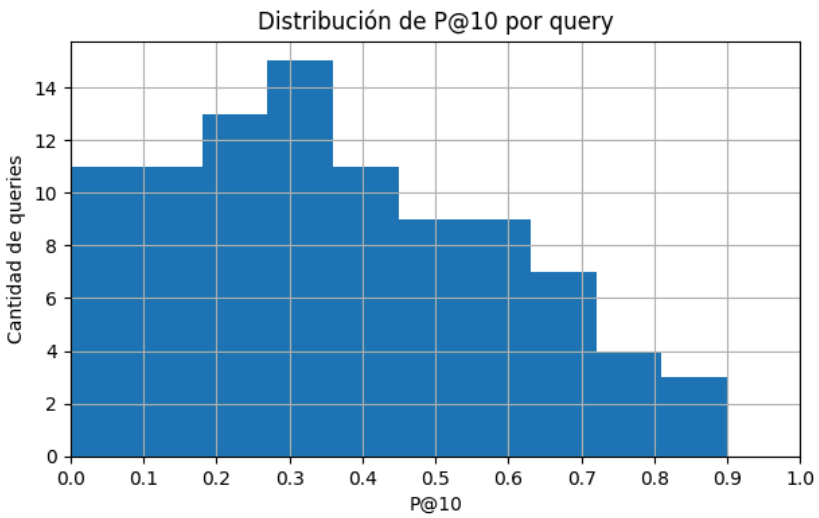

Histograma 7.2.a: p@10 por query

Por el lado de la precisión promedio los picos se ven entre 0.1 y 0.5, es decir la precisión en general de todo el SRI es baja, lo que indica rankings globales que no cumplen con las expectativas de las necesidades de información

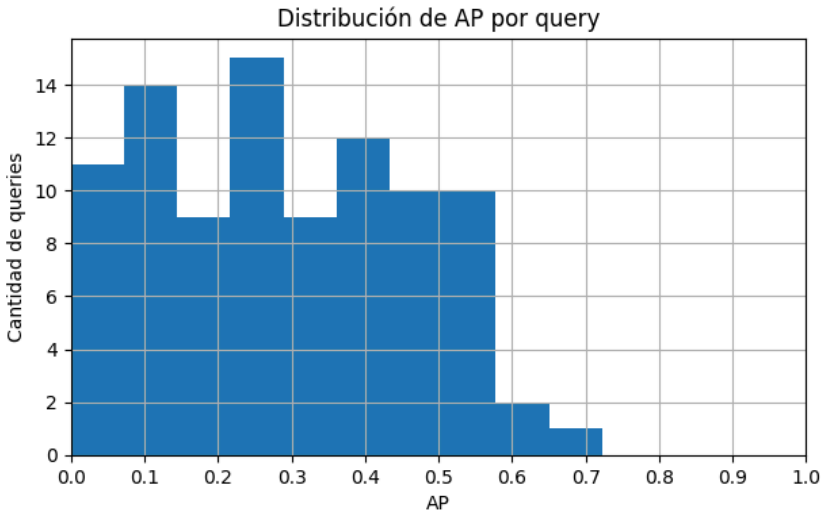

Histograma 7.2.b: Precisión promedio por query

El nDCG encuentra su pico en 0 (rankings con nulos relevantes) y en 0.5, que sigue siendo un valor insuficiente para llegar a un buen desempeño. Indicaría que se ubican pocos documentos relevantes en las primeras posiciones del ranking.

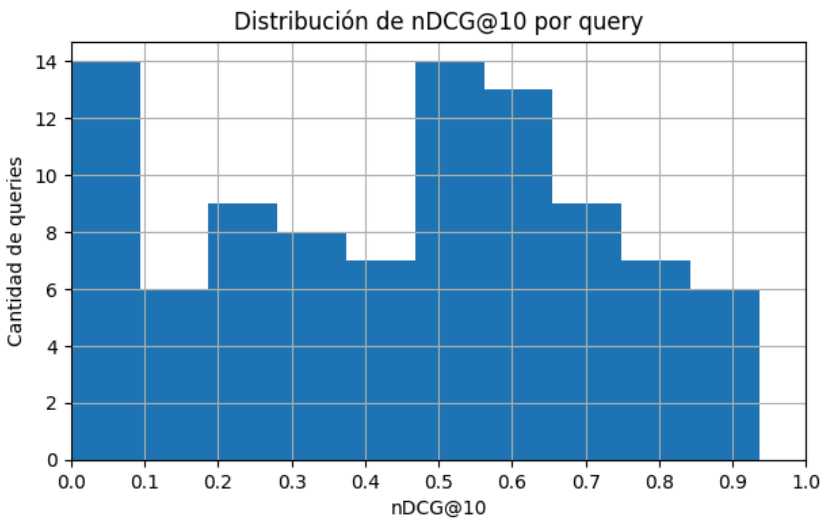

Histograma 7.2.c DCG normalizado a la posición 10 del ranking por query

Por último, al ver las distintas curvas de R-P (**Gráfico 7.2**) vemos casos muy dispares, algunos casos con una precisión óptima y en otros muy baja. Esto nos da la pauta que el sistema no es tan robusto, no generaliza sus métricas para las distintas necesidades de información, y por ende es muy dependiente del tipo de consulta que se le haga.

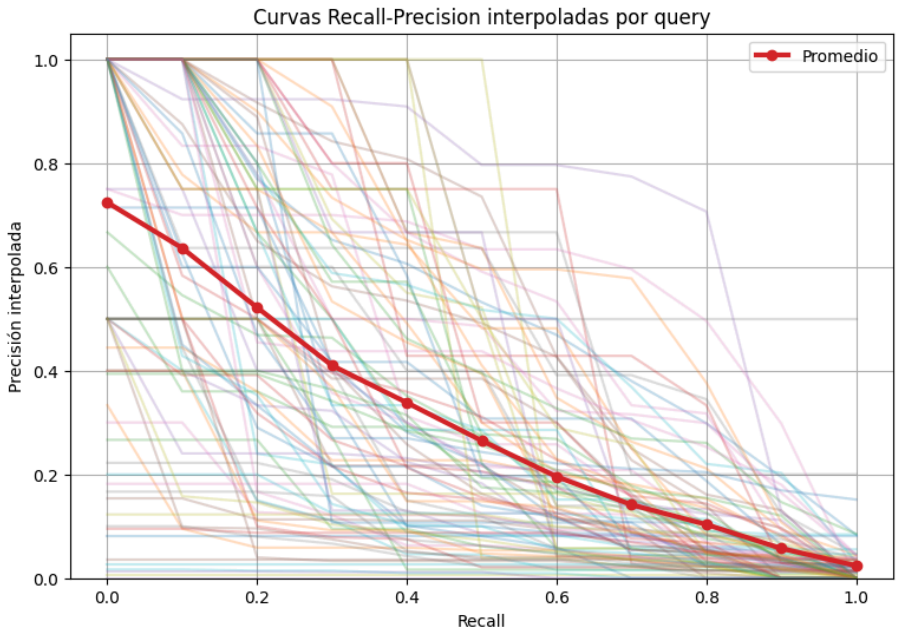

Gráfico 7.2: Precisión promedio interpolada en puntos estándar por query

8. *Dadas las salidas de tres sistemas de recuperación de información para 3 consultas cualquiera*[4] *y los juicios de relevancia creados por asesores humanos*[5] *calcule para cada sistema:*

---

[4] https://github.com/tolosoft-academia/RI_2025/blob/main/data/Ejer-Evaluacion-OUTPUT.ods
[5] https://github.com/tolosoft-academia/RI_2025/blob/main/da1/ta/Ejer-Evaluacion-JR.ods

a) La precisión media.
b) La precisión media a intervalos de Recall de 20%
c) P@5, P@10, P@20

Luego, exponga un escenario posible y medidas complementarias para decidir qué sistema utilizar.

Respuesta
Los cálculos se pueden observar en el archivo ***Punto_8.ods***, en la hoja *"metrics".*

a. La precisión media

SRI	Q1	Q2	Q3
A	0.72	0.62	0.33
B	0.23	0.29	0.35
C	0.50	0.33	0.29

b. La precisión media a intervalos de Recall de 20%

Recall	**A**	**B**	**C**
20%	0.77	0.42	0.45
40%	0.69	0.28	0.43
60%	0.42	0.28	0.41
80%	0.39	0.28	0.38
100%	0.27	0.28	0.31

c) P@5, P@10, P@20

SRI	Q1	Q2	Q3
P@5			
A	0.60	0.80	0.40
B	0.20	0.20	0.40
C	0.40	0.20	0.20
P@10			

A	0.50	0.40	0.20
B	0.20	0.20	0.30
C	0.50	0.30	0.20
P@20			
A	0.25	0.30	0.25
B	0.25	0.20	0.30
C	0.30	0.25	0.29

Un escenario común para el uso de estos sistemas podría ser una búsqueda web de Google. Para este caso, podemos ayudarnos con métricas adicionales, como la **precisión-R**

	Q1	Q2	Q3
A	0.50	0.57	0.29
B	0.17	0.14	0.29
C	0.50	0.29	0.14

Tabla 8.d: Precisión-R para cada SRI en cada consulta.

Luego también, ayudarnos visualmente para las métricas de recall tomadas antes

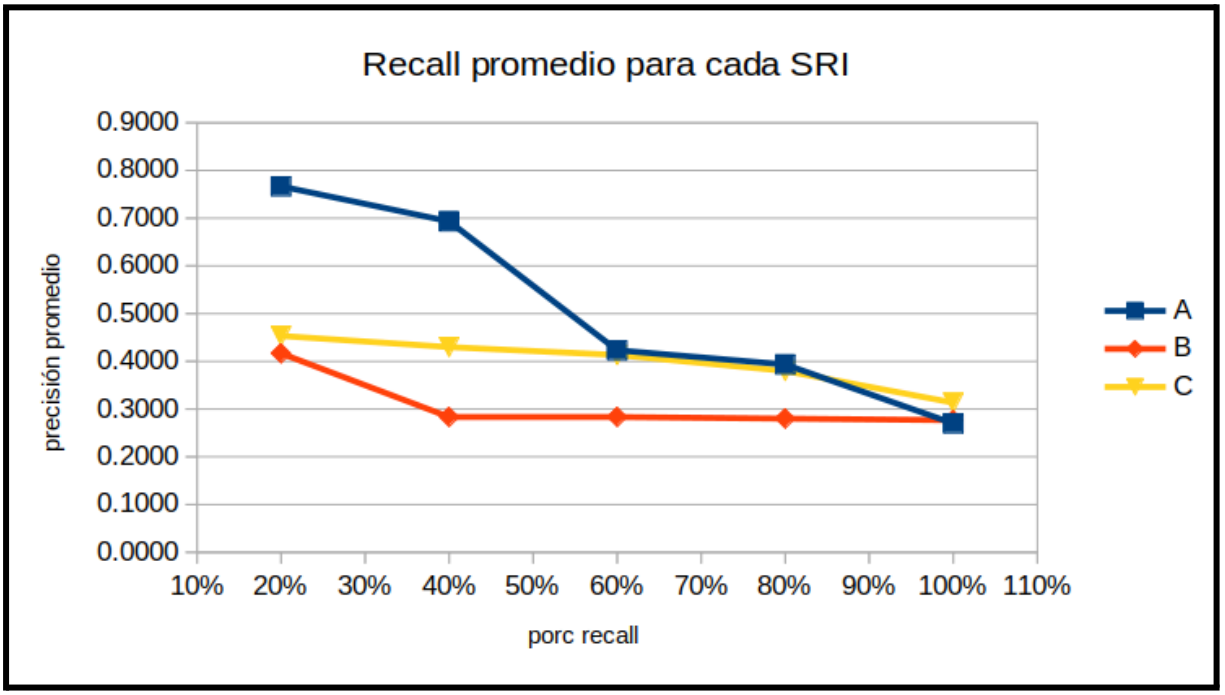

Gráfico 8: Recall promedio de cada SRI

En un caso como el planteado, **se elegiría el Sistema de RI “A”.**
En el gráfico podemos observar una precisión más alta durante los primeros niveles de exhaustividad. A su vez, la precisión-R nos dice que durante las primeras N posiciones, se devuelven más documentos relevantes, siendo N la cantidad de documentos relevantes totales, por ende tendrá mejor rendimiento en la primera página de la búsqueda, que estadísticamente es la más evaluada por el usuario en este tipo de escenarios.