

TP03

Modelos de Lenguaje

Matias Rolón

143354

1. Retome el TP de "Modelos de RI" y calcule el modelo de lenguaje (unigramas) para los documentos del ejercicio 2. Utilizando el modelo de Query Likelihood calcule los rankings para las siguiente consultas:

- a) país cultura*
- b) país libre cultura*
- c) software propietario licencia*

¿Qué problemas encuentra? Luego, calcule las probabilidades de los términos utilizando una combinación con el ML de la colección (suavizado Jelinek-Mercer, $\lambda = 0,7$). Compare con las probabilidades anteriores y explique las diferencias. Repita las consultas con los nuevos valores. Explique los resultados.

Respuesta

Al realizar el modelo de lenguaje con la versión básica del MLE (maximum likelihood estimation) vemos problemático el cálculo de muchos documentos con score en 0, ya que al ser un producto de probabilidades, cualquier término de la query que no se encuentre en el documento **anula todo el score**, independientemente de si los otros términos existen o no en el doc. Un claro ejemplo es en la query 'a' donde sólo d4 y d2 tienen ambos términos ("país" y "cultura"), el resto de docs tienen sólo uno de los dos por ende no competirán en el ranking de la manera en que se espera. Es un sistema de RI demasiado restrictivo.

Un caso todavía más complejo es cuando el término de la query no está en ningún documento de la colección, ya que en ese caso, si seguimos la fórmula original de MLE (ya sea con o sin suavizado) el score dará 0. Para tratar este caso, y teniendo en cuenta que las probabilidades de ese término que no existe serán constantes para todos los documentos por igual, **se decide no tenerlo en cuenta**. Por ejemplo, en la consulta 'c', sólo se tendrá en cuenta para el cálculo a "software" ya que tanto "propietario" como "licencia" no se encuentran en el índice.

En **Imagen 1** se pueden ver resaltados en amarillos todos los scores que dan 0 como consecuencia de esta manera de evaluar (10 scores)

Q1	doc	d1	d2	d3	d4	d5	d6
	score	0.0000	0.0051	0.0000	0.0123	0.0000	0.0000
Q2	doc	d1	d2	d3	d4	d5	d6
	score	0.0000	0.0004	0.0000	0.0027	0.0000	0.0000
Q3	doc	d1	d2	d3	d4	d5	d6
	score	0.1333	0.0000	0.0769	0.2222	0.0000	0.0769

Imagen 1.1: Scores en 0 de consultas por documento en unigramas.

Se procede entonces a realizar el suavizado Jelinek-Mercer bajo la fórmula:

$$\hat{P}(t|d) = \lambda \hat{P}_{\text{mle}}(t|M_d) + (1 - \lambda) \hat{P}_{\text{mle}}(t|M_c)$$

Fórmula 1: Suavizado Jelinek-Mercer según Manning (2008)

Donde el parámetro λ indicará el grado del suavizado, siendo mayor cuanto más cercano a 0 sea éste. En la fórmula un valor bajo le dará más importancia al peso del término en la colección, en lugar del documento. Esto hace que documentos que contienen sólo algunos de los términos sean también recuperados, lo que lo hace ideal para consultas largas, donde es menos probable que se encuentren TODOS en un sólo documento.

Con un $\lambda=0.7$ se puede observar diferencias significativas en las probabilidades, donde ahora ya no hay scores que den 0.

Q1	doc	d1	d2	d3	d4	d5	d6
	score	0.000140	0.003824	0.000778	0.004315	0.000831	0.000140
Q2	doc	d1	d2	d3	d4	d5	d6
	score	0.000010	0.000282	0.000018	0.000567	0.000068	0.000011
Q3	doc	d1	d2	d3	d4	d5	d6
	score	0.1170	0.0237	0.0775	0.1792	0.0237	0.0775

Imagen 1.2: Scores de consultas por documento en unigramas+suavizado.

Al repetir las consultas con estas nuevas probabilidades suavizadas, vemos que se pueden completar los rankings en su totalidad para las queries 'a' y 'b', disminuyendo drásticamente los empates entre puntajes de un documento y otro. Mientras tanto, la query 'c' respeta las mismas posiciones.

Además, las probabilidades de los términos que sí se encuentran en el documento bajan levemente su score con el método de suavizado, ya que con un $\lambda=0.7$ hay un 0.3 (30%) que se inclina hacia las probabilidades que hay en la colección en lugar de abarcar un 100% de las probabilidades del documento. Por ejemplo, para la Query 'a' en 'd1' el MLE nos daba un 0.0123 y con Jelinek-Mercer nos da 0.0043

Query	Unigramas	Unigramas + Suavizado JM
a	1. d4 2. d2 3. d1, d3, d5, d6	1. d4 2. d2 3. d5 4. d3 5. d1, d6
b	1. d4 2. d2 3. d1, d3, d5, d6	1. d4 2. d2 3. d5 4. d3, d6 5. d1
c	1. d4 2. d1 3. d3, d6 4. d2, d5	1. d4 2. d1 3. d3, d6 4. d2 d5

Tabla 1: Comparación Rankings con y sin suavizado.

2. Repita el ejercicio pero esta vez utilice la divergencia de Kullbak-Leiber y un suavizado por Dirichlet-Priors utilizando para los parámetros los valores sugeridos en la literatura.

Respuesta

Se utiliza un valor de $\mu = 60$.

En Zhai, C. y Lafferty, J. (2001) hacen referencia a un valor de 2000 para documentos de 300 a 500 tokens, pero aca tienen entre 9 y 15 tokens. Creemos que 2000 aumentaría el suavizado demasiado, dándole casi la totalidad de la importancia a las probabilidades de la colección solamente y nada a las del documento.

Por eso, nos disponemos a hacer una regla de tres simples. Si para 500 tokens por doc μ es 2000, para 15 tokens por doc es: $(15 \cdot 2000) / 500 = \mathbf{60}$

De esta manera siguiendo la fórmula del suavizado:

$$\hat{P}(t|d) = \frac{\text{tf}_{t,d} + \alpha \hat{P}(t|M_c)}{L_d + \alpha}$$

Fórmula 2: Suavizado Dirichlet Prior según Manning (2008)

Dado que mientras más aumenta μ más importancia se le da a la colección, si tomamos el largo máximo de un documento (15) el denominador de la fórmula nos quedaría en $15 + 60 = 75$, es decir que el “prior” sería un 80% del denominador.

En cambio, sí tendríamos un valor de $\mu=2000$ tomándolo tal cual del ejemplo de la bibliografía mencionada, la importancia de la colección abarcaría más de un 99% del denominador, por ende el aporte del documento sería imperceptible.

Al igual que el ejercicio anterior, para la consulta 'c' se excluyeron del cálculo de Dirichlet Prior aquellos términos de la query que no aparecían nunca en toda la colección.

Query	Suavizado DP + Divergencia KL
a	1. d4 2. d2 3. d5 4. d3 5. d6 6. d1
b	1. d4 2. d2 3. d5 4. d3 5. d6 6. d1
c	1. d4 2. d1 3. d3, d6 4. d5 5. d2

Tabla 2: Ranking con suavizado Dirichlet Prior.

Observando el ranking final, podemos ver mucha similitud en las posiciones, con la diferencia de que en este segundo método de suavizado disminuyen todavía más los *scores* empatados, como por ejemplo la posición de d1 y d6 en la query 'a', o la posición de d3 y d6 en la query 'b'.

La forma de evaluar el ranking es ligeramente diferente ya que aquí un score alto nos indica que se tiene una mayor diferencia entre el modelo del documento y el modelo de la query, por lo que se buscaron primero los valores más bajos.

Por fórmula, Dirichlet tiene una mejor adaptación a los distintos largos de los documentos, teniendo mayor suavizado cuanto más largos sean (mayor número de tokens). En este caso, al ser documentos muy cortos, puede ser una razón para que la diferencia entre ambos métodos no resalte mucho.

3. Utilizando modelos de lenguaje en pyTerrier repita los experimentos del ejercicio 7 del TP de "modelos" y compare los resultados con los anteriores. ¿Son consistentes? Calcule las métricas apropiadas para comparar los diferentes sistemas y configuraciones.

Respuesta

Nos proponemos evaluar los 3 modelos partiendo de la notebook usaba en el TP02 del ejercicio 7¹, de manera que quedan las siguientes configuraciones:

Wmodel	Modelo	Parámetros
TF_IDF	TF-IDF	-
Hiemstra_LM	Jelinek-Mercer (JM)	$\lambda=0.9$
DirichletLM	Dirichlet Priors (DP)	$\mu=2000$

Tabla 3.1: Configuración de modelos en el código.

Por el lado del análisis global, podemos observar que TF-IDF tiene mejor promedio en los valores de sus métricas principales, seguido muy de cerca por Jelinek-Mercer, y diferenciándose bastante ambos del rendimiento de Dirichlet Priors, muy por debajo, con más de un 50% menos en cada una de las métricas .

Modelo	AP	P@10	nDCG@10
TF-IDF	0.2905	0.3591	0.4443
Jelinek-Mercer ($\lambda=0.9$)	0.2791	0.3548	0.4328
Dirichlet Priors ($\mu=2000$)	0.1306	0.1419	0.1319

Tabla 3.2: Promedio de las métricas de cada modelo

Los bajos resultados de DP pueden deberse al valor de $\mu=2000$, ya que se decidía usar el aplicado en la bibliografía viendo que esta colección era mucho más grande que la del ejercicio, pero al seguir teniendo menos tokens por documento el valor le queda grande y siempre prioriza el modelo de la colección.

Al realizar la Curva de Recall-Precision en los 11 puntos estándar, sigue observándose la misma tendencia, TF-IDF y JM parecen casi superpuestas con JM levemente inferior. A diferencia de DP que ya desde el comienzo tiene una precisión muy baja de 0.3, y luego decae rápido.

¹ Teniendo en cuenta la corrección del equipo docente, se cambia la forma en la que se calculan las métricas, usando las herramientas que ya provee PyTerrier.




Gráfico 3.1: Curva RP en 11 niveles estándar para los 3 modelos.

Con respecto a los rankings se calcula la Correlación de Spearman sobre los mismos:

Ranking 1	Ranking 2	Coef de Correlación
TF-IDF	Jelinek-Mercer ($\lambda=0.9$)	0.9019
TF-IDF	Dirichlet Priors ($\mu=2000$)	0.6124
Jelinek-Mercer ($\lambda=0.9$)	Dirichlet Priors ($\mu=2000$)	0.5527

Tabla 3.3: Coeficiente de correlación entre los 3 rankings

Son consistentes con lo observado, dado que TF-IDF tiene mucha correlación (0.9) con JM, lo cual vimos reflejado antes en las métricas y gráficos expuestos. Luego la correlación entre estos dos y Dirichlet Priors se aleja bastante siendo de un 55% de semejanza, lo que no es un porcentaje alto.

Ya mencionado lo que pudo haber afectado a DP, se puede suponer que por la misma razón (los parámetros que rigen el suavizado) lo que hace a JM parecerse mucho a TF-IDF es el valor de lambda ($\lambda=0.9$) ya que cuanto más grande sea su valor, más importancia se le dará a la probabilidad del documento y por ende se asimilará a la fórmula original de TF-IDF, sin darle mucha relevancia a la colección.

Por último, por el lado del análisis por *query*, graficamos la distribución de sus valores para cada concepto medido, resaltando DP en la parte izquierda de cada gráfico, lo que indica que concentra muchas consultas con bajos resultados en cada una de las métricas. Además, JM y TF-IDF siguen parecidos, con una concentración de JM levemente mayor en las zonas bajas y medias del eje X (de 0.1 a 0.5), lo que hace compensar a TF-IDF que tiene valores levemente mayores en las zonas altas. El gráfico es intuitivo salvo por la métrica nDCG donde TF-IDF acumula más en 0.3 y JM tiene mayor concentración en 0.7, lo que a priori indicaría un mejor comportamiento de éste último, pero TF-IDF compensa teniendo unas pocas instancias más en niveles altos (0.8), por lo que el promedio visto en la **Tabla 3.2** seguiría favoreciendo a éste último.




Gráfico 3.2: Distribución por query de cada métrica

De esta manera queda claro que los modelos de lenguaje evaluados son muy sensibles al tuning de sus parámetros de suavizado, y por ende al contexto donde se lo apliquen. No existe un valor absoluto que dé un rendimiento superior sino que depende de la colección y el tipo de consultas que se va a realizar.